
内容列表可在[ScienceDirect](https://www.sciencedirect.com)上找到

国际工业工效学杂志

杂志主页: <http://www.elsevier.com/locate/ergon>

使用小波深度信念网络进行上肢的单通道SEMG运动识别

邵俊凯^a, 牛亚峰^{a,b}, 薛成奇^{a,*}, 吴群^c, 周小舟^a, 谢毅^b, 赵小莉^a^a中国南京市苏园路东南大学机械工程学院, 211189^b中国洛阳凯旋西路光电控制科学与技术实验室, 471023^c中国杭州下沙高教园区浙江科技大学通用设计研究所, 310018

我的朋友们, 你们好吗?

关键词。

单通道SEMG 运动识别

奇异值分解(SVD)

小波深度信念网络(WDBN)

A B S T R A C T

表面肌电图 (SEMG) 已被广泛应用于人机交互和运动识别等不同领域。本文首次提出了一种基于奇异值分解 (SVD) 和小波深度信念网络 (WDBN) 的混合分类模型, 使机器可以通过一个通道识别上肢的单关节运动。在本实验中, 上肢的三个关节的SEMG信号分别通过不同的两个通道记录, 并采用这两个通道进行后续比较, 以获得每个关节的最佳单通道。之后, 通过SVD处理对收集的原始信号进行增强。应用小波函数代替普格玛函数作为特征学习的激活函数, 并将经过快速傅里叶变换 (FFT) 处理的频谱信号输入到WDBN模型。结果表明, SVD-WDBN方法对三个关节运动的识别率可达100%, 比支持向量机 (SVM)、反向传播 (BP) 神经网络和极端学习机 (ELM) 模型好得多。该方法使控制不同单通道SEMG信号的可穿戴设备成为可能, 从而提高了智能可穿戴设备的工作效率, 并降低了人与机器之间的操作复杂性。

1. 简介

表面肌电图 (SEMG) 信号可以显示工作时肌肉的生理特征, 在各个领域都有广泛的应用, 尤其是在假肢控制和肌电图模式识别方面 (Constantinescu等, 2016; Liu和Wang, 2018)。由于人体的SEMG信号很弱, 容易受到干扰, 难以获取。因此, 提取有效的信号特征成为SEMG信号处理的第一环节 (Chowdhury等人, 2013)。显然, 通过将复杂的多分量弱信号划分为许多单分量信号, 可以显著提高信号分类的准确性。奇异值分解 (SVD) 可以有效地减少SEMG信号中的随机噪声, 削减特征向量的规模 (Patidar等人, 2013)。此外, 一些研究者还尝试将SVD与其他算法相结合, 如小波包变换 (WPT) (Karimi, 2012)、局部判别分析 (LDA) (Rekhi等, 2011; Yan等, 2019a, b), 以获得出色的识别性能。

目前, 许多关于SEMG信号识别的研究倾向于

采用多通道信号采集, 主要是针对不同的复杂手势 (Geethanjali和Ray, 2011) 和精细的关节运动 (Matrone等人, 2012), 尤其是在多类复合运动的识别上 (Phinyomark等人, 2013)。同时, 良好的识别性能主要依赖于不同特征的组合和分类器的选择。提取了SEMG时域和呼吸振幅的15个特征, Yang等人, 2017年, 他们通过人工神经网络 (ANN) 从SEMG和呼吸信号中有效识别了佩戴呼吸器的不同气道阻力。此外, Khushaba等人 (2012) 通过提取不同的特征集并比较两个分类器, 成功识别了手势, 识别率达到90%。然而, 上述传统的模式识别方法主要以浅层特征为代表, 这些特征取决于先验条件和设计特征 (Yan等人, 2019a,b)。其特征信息仍需改进, 其可靠性也需要进一步提高。目前, 只有少数关于单通道信号识别的研究, 识别精度不高 (Xiong等人, 2016)。随着通道的增加, 在

* 通讯作者。

电子邮件地址: ipd_xcq@seu.edu.cn (C. Xue)。<https://doi.org/10.1016/j.ergon.2019.102905>

2019年3月29日收到; 2019年12月25日收到修订版; 2019年12月25日接受

2020年1月3日可上网查询

0169-8141/© 2020 Elsevier B.V.保留所有权利。

分类精度将得到提高，但信号处理的复杂性也将增加。此外，更多的测试通道可能造成操作上的不便。这些问题大大阻碍了识别技术的效率和自动化、智能化的发展。因此，应用较少的采集通道来获得更有效的特征表示和更稳定的分类模型，这已成为动作识别的关键技术。

近年来，深度学习被广泛应用于SEMG信号的特征提取（Cham-bon等人，2018；Hinton等人，2012）。与传统的学习方法相比，深度学习可以从大数据中自动学习特征（Chen等人，2015）。通过提取多级特征并将其转移到顶层，形成适合模型分类的更抽象的特征向量，可以提高分类或预测的准确性（Xia等人，2018）。作为深度学习的经典模型之一，深度信念网络（DBN）使底层数据通过神经网络，并将其提取为高层次的有意义的特征表示（Tamil-selvan和Wang，2013；O'Connor等人，2013）。此外，它可以减少过度拟合，解决传统多层感知器中难以解决的局部最小值问题。然而，将标准的受限玻尔兹曼机（RBM）直接应用于表面EMG模式识别是一个挑战（Chen等人，2018）。实际上，收集到的SEMG信号是非稳态的，并且在肢体运动过程中是有噪音的。标准RBM的激活函数一般选择sigmoid函数，这很难在许多模式和输入信号之间建立准确的映射关系。目前许多研究已经证明，作为浅层神经网络的新激活函数，小波神经网络（WNN）

通常比传统的神经网络显示出明显的优势（Yang and Hu, 2016; Khan et al., 2017）。小波变换可以通过缩放平移逐步多尺度细化SEMG信号，具有时频定位的特点。然而。

目前，关于小波方法在各种深度学习模型中的应用的研究很少。因此，结合深度信念网络和小波变换的优势，提高动作识别的效率具有重要意义。

本文针对上肢运动提出了一种基于SVD-WDBN的混合分类模型--

通过使用相应的单通道，可以准确识别肩部、肘部和手腕的多类运动。结果表明，经WDBN分类后，上肢运动的SEMG信号的识别率可达到100%，优于基于SVM、BP和ELM的传统方法。

2. 材料和方法

2.1. 数据收集

上肢运动是人类日常生活中的一种重要活动方式。本文的主要目的是利用不同单通道的SEMG信号来识别上肢的三个关节运动。SEMG数据可以从8名健康男性的右手上获得。他们的年龄在22至30岁之间，没有任何肌肉疾病。所有参与者必须听从观察者的指示，并注意节拍器的提示音。他们需要分别完成12个基本动作。每个动作需要做5次，每次5秒。完成一个基本动作后，参与者应休息2分钟以避免肌肉疲劳。任务模式循环进行，直到所有的实验动作都完成。

首先，对12个基本动作进行分类，并给出具体代码。关节运动主要包括肩关节屈曲（S1）、肩关节伸展（S2）、肩关节外展（S3）、内旋（S4）、外旋（S5）、肘关节屈曲（E1）、前臂突起（E2）、前臂上举（E3）、腕关节屈曲（W1）、腕关节伸展（W2）、尺偏（W3）、桡偏（W4），见图1。之前

实验中，每个参与者都练习了半小时，熟悉了所有的上肢运动。在上肢的每个关节中选择两块信号变化明显的肌肉，通过实验获得最佳单通道。（肩部：肩部：中三角肌/背阔肌；肘部：肱二头肌。Ch3-肱二头肌/Ch4-桡骨柔韧肌；腕部：腕部：Ch5-尺骨柔韧肌/Ch6-指伸肌）。图2显示了这三个关节的电极位置。

肌肉的皮肤表面用细砂纸和酒精棉球清洁，然后将导电电极连接好，以确保高信噪比（SNR）。通过美国Motion Lab Systems公司生产的MA300系统从两个肌肉通道采集每个关节运动的信号，采样频率设定为1000赫兹，同时在计算机中显示实时原始SEMG信号。

2.2. 奇异值分解

SVD可以简化数据，消除噪音和多余的数据。在奇异值分解中，应构建合适的特征矩阵，如Toeplitz矩阵、Cycle矩阵和Hankel矩阵（Jiang等人，2015）。SEMG信号的能量分布随肌肉收缩而变化，汉克尔矩阵的奇异值可以准确地显示SEMG信号中噪声的成分活动和能量分布（赵和叶，2009）。因此，本文采用汉克尔矩阵来重建矢量空间。

对于受噪声干扰的一维离散SEMG信号， $X = [x_1, x_2, \dots, x_L]^T$ ，可以构建一个 $m \times n$ 维度的汉克尔矩阵。73

$$H_{m,n} = \begin{bmatrix} x_1 & x_2 & \dots & x_n \\ x_2 & x_3 & \dots & x_{n+1} \\ \vdots & \vdots & \ddots & \vdots \\ x_m & x_{m+1} & \dots & x_{m+n-1} \end{bmatrix} \quad (1)$$

在公式（1）中， H 指的是汉克尔矩阵， m 指的是嵌入维度，它满足 $m \leq n-1 \leq L$ 的条件。

通过SVD分解，得到公式（2）。

$$H \approx U \Sigma V^T \quad (2)$$

在公式（2）中， U 指的是 $m \times m$ 维度的正交矩阵， V 指的是 $n \times n$ 维度的正交矩阵，而 Σ 指的是 $m \times n$ 维度的矩阵。

$$\Sigma = \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_r \\ & & & & 0 \end{bmatrix} \quad (3)$$

在公式（3）中， $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_r)$ 和 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r$ ，其中 r 是Hankel矩阵的等级。降噪的具体过程是将剩余的奇异值设为零，保留第一

k 个奇异值。之后，在重建的矩阵可以通过奇异值分解的逆过程得到，通过反转得到去噪信号。

2.3. 小波深度信念网络

DBN由多个受限玻尔兹曼机（RBM）组成，它可以通过一系列非线性的方法从原始数据中自动提取从低级到高级的抽象特征。

变换。RBM网络由三个参数组成：可见层和隐藏层之间的权重矩阵 $W_{n \times m}$ ，可见节点偏移量 $b = [b_1, b_2, \dots, b_n]^T$ 和隐藏节点偏移量 $c = [c_1, c_2, \dots, c_m]^T$ 。如果一个RBM有 n 个可见单元和 m 个隐藏单元， V_m 代表第 m 个可见单元的状态，而 H_n 代表第 n 个隐藏单元的状态。对于给定的 V 和 H 集合的状态，RBM的能量函数可以定义为



图1.12个基本动作的演示。




图2.右臂上的电极位置。

$$E_{RBM} \delta V; H_j \theta p \frac{1}{4} - X V W H_{mnm} - X b V_{mm} - \frac{X c H_{nn}}{(4)}$$

在公式 (4) 中, θ 是RBM的一个参数, 它是一个实数; W_{nm} 代表连接权重; b_m 代表可见的偏移量。

隐层单元 m 和 c_n

代表可见层单元 n 的偏移。基于能量函数, 隐层 V 和可见层 H 的联合概率分布可以表示为

$$P \delta V; H_j \theta p \frac{1}{4} e^{-E_{RBM} \delta V; H_j \theta p} \quad (5)$$

将公式 (5) 中的 $Z(\theta)$ 设为归一化系数。

$$Z \delta \theta p \frac{1}{4} e^{-E \delta V; H_j \theta p} \quad (6)$$

观察数据 V 的概率分布 $P \delta V$; $H_j \theta p$ 的边缘分布相呼应, 这也被看作是一个似然函数。对应数据的边缘分布为

$$P \delta V_j \theta p \frac{1}{4} X P \delta V; H_j \theta p \frac{1}{4} 1 \quad Z \delta \theta p X e^{-E \delta V; H_j \theta p} \quad (7)$$

类似地, 公式 (8) 可以得到如下结果

$$P \delta H_j \theta p \frac{1}{4} X P \delta V; H_j \theta p \frac{1}{4} 1 \quad Z \delta \theta p X e^{-E \delta V; H_j \theta p} \quad (8)$$

小波函数的方程表示如下

$$\psi(x) = \frac{1}{\sqrt{2\pi}} \sum_{k=1}^m W_{jk} x_k - d_j \quad (9)$$

其中 m 为输入层和输出层的单元数, 隐层单元的单元数为 p ($j = 1, 2, \dots, p$)。其中 ζ 是小波激活函数, x_k 是训练样本, c_j 和 d_j 是小波激活函数的比例因子和移动因子。

小波变换 (WT) 是一种新的变换分析方法, 它继承和发展了短时傅里叶变换局部化的思想, 同时也克服了窗傅里叶变换的缺点。它是一种理想的时频分析和信号处理工具, 可以提供一个随频率变化的时频窗口。本文采用 Morlet 小波的实部作为非线性激活函数来设计 WDBN, 可以表示为:

$$\zeta \delta q p \frac{1}{4} \cos \delta 5 q p \exp(-q^2 \cdot 2) \quad (10)$$

$$H_j \delta \text{out} p \frac{1}{4} \zeta \delta q p \frac{1}{4} \cos \delta 5 q p \exp(-q^2 \cdot 2) \quad (11)$$

多个 WRBM 可以组成一个 WDBN 模型, 如图 3 所示。每一层都从前一个隐藏层捕捉高度相关的关联。每个低层的 WRBM 作为输入数据用于训练下一个 WRBM, 它尽可能多地循环使用, 并通过微调给定参数进一步提高网络的特征提取能力。

2.4. SVD-WDBN 分类方法

SVD 对于非线性和非静止的弱信号处理具有良好的稳定性和不变性 (Lehtola 等人, 2008)。它能最大程度地提取 SEMG 的特征信息, 并能重建和增强信号特征。整个识别过程

流程图见图 4。首先, SVD 降噪技术

应用于增强原始 SEMG 信号, 然后通过 FFT 将增强后的信号进一步处理为频域信号。最后, 应用 WDBN 来逐层提取高级特征

从处理过的信号中, 实现有效的分类。

J. Shang et al. 本文利用小波函数代替传统的sigmoid函数，构筑了一个新的小波深度信念网络（WDBN），该网络对复杂的非稳态振动信号的代表性形成有很强的捕捉能力。具体

本文将SVD信号增强和WDBN智能分类的优点有机地结合起来，形成了一种识别上肢运动SEMG信号的新方法。该方法主要分为两个阶段。
微弱信号增强阶段。

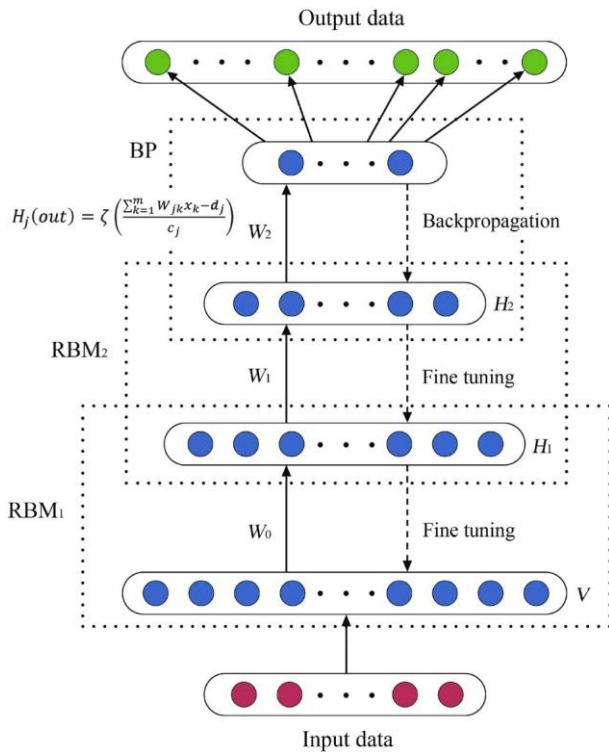


图3.WDBN的原理结构图。

步骤1：获得SEMG信号；步骤2：初始化SVD参数。

第三步：分解和重建早期的弱信号，以获得增强的信号。

第四步：通过FFT将归一化信号转换成频谱信号，然后将这些信号分为训练样本和测试样本。

智能识别阶段。

第五步：执行小波函数作为激活函数，初始化WDBN模型参数。

第六步：使用未标记的样本来训练WDBN模型，通过无监督的CD方式确定每层的隐藏层数（N）。

第七步：略微调整模型参数，根据样本标签保存网络结构。

第八步：获得WDBN模型，对测试样本进行测试和分类，并生成分类结果。

3. 结果和讨论

本文重点讨论了上肢运动的单通道SEMG信号识别，这对控制人形机械和假肢具有实际应用意义。

在第一个实验中，通过SVD对SEMG信号进行增强，比较SVD降噪前后的时域和频域效果。在第二个实验中，用WDBN对不同通道采集的原始信号和去噪信号进行分类，分析了数据分布的聚类和分类特点，比较了两种处理方法下的识别精度。最后，确定了每个关节的最佳单通道的SEMG识别。第三个实验是基于各关节的最佳单通道信号，将WDBN的识别效果与其他分类方法进行比较。

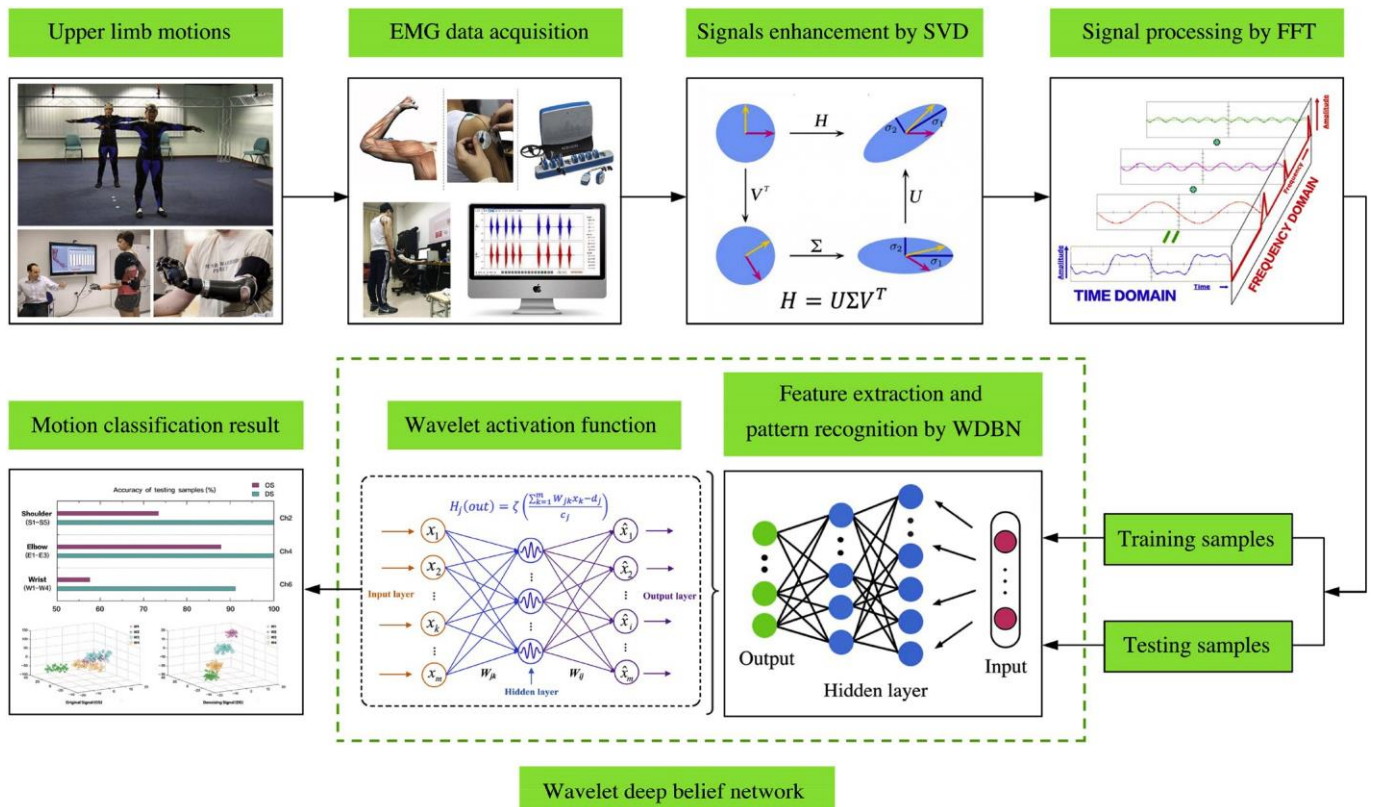


图4.整个识别流程图。

3.1. 评估SVD的性能

SEMG信号非常弱，容易受到外部环境和内部因素的影响，这使得提取有效特征更加困难。因此，信号去噪一直是信号处理中一个非常重要的步骤。为了评估SVD在信号分解和特征提取方面的性能，我们在时域和频域分析了SEMG信号的波形特征，并通过基于FFT的方法得到频谱信号。由于显示空间有限，图5和图6中只显示了Ch1上三个动作的原始信号（OS）和去噪信号（DS）。

三个SEMG信号降噪前后的时域波形如图5所示。可以看出，不同的上肢运动有不同的特征频率，其波形也非常明显。在时域波形中，大量的噪声被去除。对S1、S2和S3的SEMG信号进行SVD降噪后，信号的一些重要特征基本被保留。

降噪前的频谱信号波形比较杂乱，图6中的影响成分并不明显。然而，降噪后三种运动的频谱特征频率变得更加突出。同样，能量冲击成分都出现在30赫兹和50赫兹之间，这也是有道理的。这是因为原始信号中的干扰和交叉成分被分离出来，而信号中较大的特征成分可以被保留。

一般来说，传统信号的时频分析不能量化上肢运动的特征信息，其描述能力有限。然而，SVD可以有效地加强信号中的弱成分，并抑制后置地噪声。本文选择经过FFT处理的频谱信号作为输入信号。

3.2. WDBN的识别精度

本节基于SVD去噪信号和未经处理的原始信号，以小波函数为激活函数，构建了一个新的WDBN模型，首先采用该模型来识别12种上肢运动。每个动作使用5,000次采样

点作为一个样本组。8名受试者共构建了200（8×5×5）个肩部样本。肘部样本的数量为120（8×5×3），手腕样本的数量为160（8×5×4），其中50%为用作训练样本，另外50%作为测试样本。WDBN参数设置为双层RBMs特征层，神经网络设置为5000-100-100-12。考虑到算法的稳定性和收敛速度，后向微调中的学习率 ϵ 和 α 均取共同值0.1。初始迭代次数设定为100次。测试重复20次，平均值被认为是最终的识别结果。

模型训练的效果主要取决于给定测试样本的识别率，换句话说，训练后的WDBN模型能识别多少测试样本。在本节中，WDBN模型被用来识别两个信号源，包括原始信号（OS）和去噪信号（DS），并最终得到测试数据集的分类结果。为了更直观地比较这两种分类结果之间的差异，我们展示了Ch2/Ch4/Ch6上三个运动测试样本的识别率。

通过对比图7的测试样本结果，可以发现对于经过WDBN分类的原始信号，整体识别效果并不高。经过降噪后，三个关节的分类结果有了明显改善。尤其是肩部和肘部运动的识别精度可以达到100%。这说明SVD降噪后，SEMG信号的冗余信息被消除，WDBN的分类性能得到有效提升。值得注意的是，在降噪后的信号分类中，一些腕部动作的测试数据样本仍然无法识别。

图8显示了对手腕上80个测试样本的更详细的分类。可以看出，原始信号中的一些测试数据点没有被准确分类。一方面，由于原始信号的信噪比较低，加上背景噪声的干扰，这些导致了太多的无用信息，阻碍了分类器的训练识别。另一方面，SEMG模式和关节运动的精细度之间可能存在一些差异。首先，人类的肩部和肘部运动属于一个广泛的关节运动范围。因此，肌肉产生的信号的能量特征更加丰富，这有利于模型的精确分类。其次，腕部肌肉的采集面积相对较小，容易受到以下因素的干扰

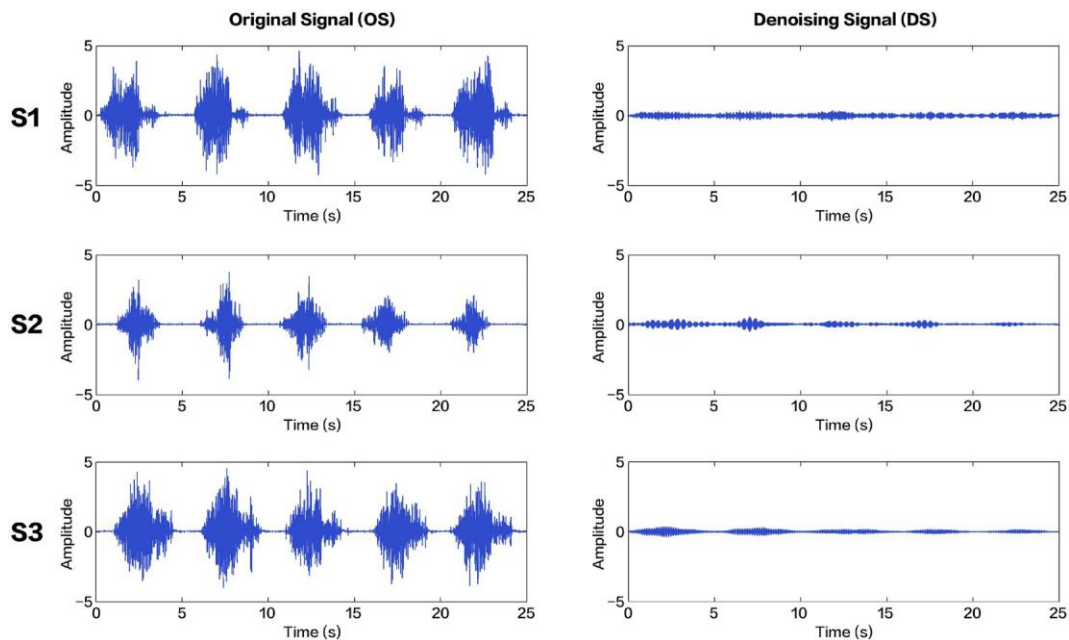


图5.降噪前后的时域波形（S1/S2/S3）。

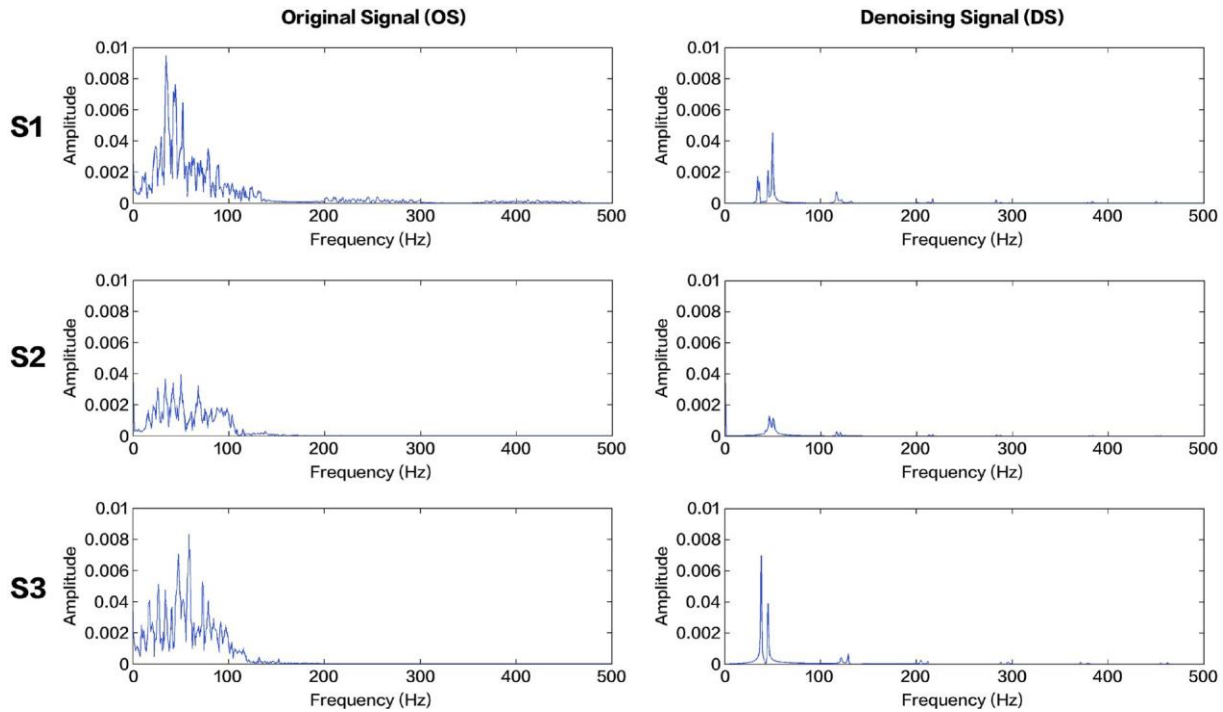


图6.降噪前后的频谱图 (S1/S2/S3)。

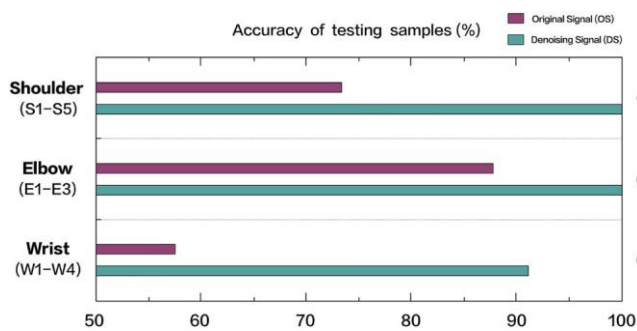


图7.降噪前和降噪后的测试样本识别率。

相邻的肌肉群，而选自肩关节和肘关节的肌肉属于大肌肉群，可以提供更可靠和全面的数据特征。因此，分类效果

肩部和肘部的运动可以达到100%。

通过t分布的随机邻居嵌入 (t-SNE)，可以有效地将信号增强前后的两个分类结果可视化，这有利于我们更直观地分析数据分布。在这一节中，为了加速计算不同维度点之间的成对偏好，并在不严重扭曲点之间距离的情况下抑制一些噪音。使用主成分分析 (PCA) 算法将特征数据的维度降低到50，同时使用t-SNE算法将50维的表示方法转换为3维的地图。图9-11显示了8个受试者的总样本分布。

以上三幅图表明，由原始信号识别的12种运动的数据分布具有不同程度的交叉和融合。三种关节运动的整体样本分布比较松散，聚类效果较差。例如，在肩部的五个动作中，只有S2和S4表现出较好的分离效果，其他三个动作都有重叠，因此很难准确分类。然而，在这些数据点中




图8.腕部运动的测试样本的分类 (W1-W4)。




图9.肩部运动的总样本分布 (S1-S5)。

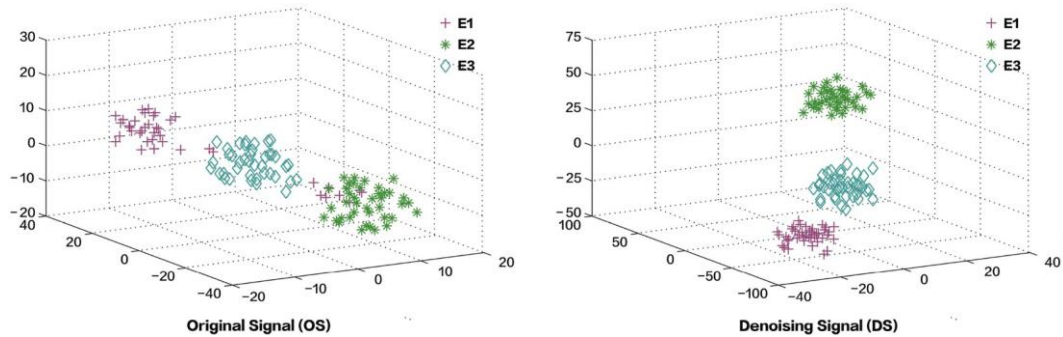


图10.肘部运动的总样本分布 (E1-E3)。

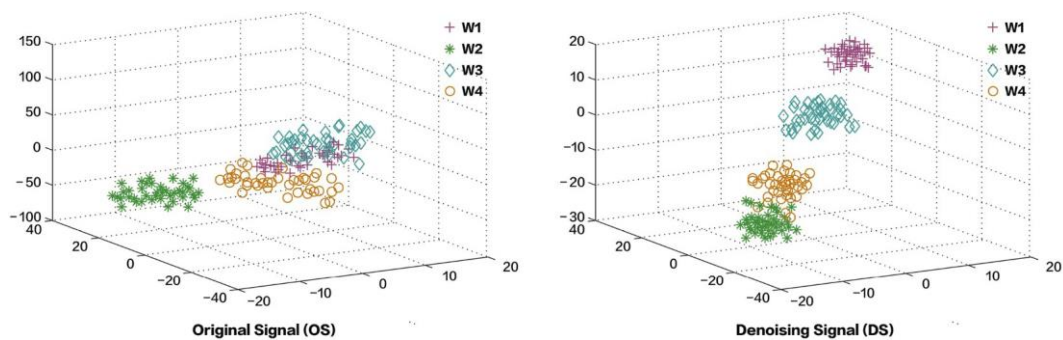


图11.腕部运动的总样本分布 (W1-W4)。

由去噪信号识别的肩、肘和腕部运动同时呈现出类内距离小、类间间距大的分布特征。提取的特征具有良好的可分离性，可以用来对12种类型的运动进行分类。这证明通过SVD增强信号后，数据样本的三维特征的聚类 and 分类效果最好。

3.3. 选择最佳通道

正确选择可用于识别上肢运动的SEMG通道是非常重要的，因为它可以提高不同模型的分类准确性。表1显示了三个关节的通道识别率，包括训练样本和测试样本。可以看出，信号增强后的整体识别率要比未增强的识别率好得多。这表明，经过SVD处理的SEMG信号提高了WDBN的分类能力和泛化性能。

与基于原始信号的WDBN分类方法相比，它具有明显的优势。这是因为SVD可以减少SEMG信号的干扰成分，消除冗余，便于后期WDBN的特征学习和分类。

从表1可以看出，每个关节都有一个最佳的单通道，识别率为100%。肩膀动作识别的最佳通道是Ch2。肘部动作的两个通道性能最好，而腕部动作的最佳通道是Ch5。因为SEMG的采集过程很容易受到许多因素的干扰。

表1
三个接头的通道识别率。

输入信号	第一章 (S1-S5)	第二章 (S1-S5)	Ch3 (E1-E3)	第四章 (E1-E3)	第五章 (W1-W4)	第六章 (W1-W4)
操作系统	0.8	0.76	0.917	0.917	0.725	0.613
卫星	0.95	1	1	1	1	0.938

识别率中的一些误差是可以接受的。

3.4. 与不同分类器的比较

长期以来，基于SVM或BP的分类器已经成为一种流行的方法，并提高了分类精度。此外，ELM的应用在SEMG信号识别领域也取得了很大进展（Wu et al., 2017; Cao et al., 2015）。在前面的章节中，通过SVD可以有效地增强弱信号，达到良好的降噪效果，并确定最佳识别通道。

在本节中，基于各关节的最佳单通道，在不同的条件下使用WDBN和其他分类器得到上肢运动识别的平均数。SEMG信号容易受到许多随机干扰的影响，包括电流干扰、物理质量或实验环境。为了验证SVD-WDBN的抗噪声能力，在其他参数不改变的情况下，如训练样本和测试样本的比例，SVD-WDBN的平均值为0.1。原始数据与干扰系数 a ($a \in \{0.2, 0.4, 0.6\}$) 混合。和0.8的rand噪声分别加入到实验数据集中）。因此，数据集 x 变为 $x_{new} = x + a \cdot \text{rand}(\text{size}(x))$ ，其中 $\text{size}(x)$ 代表信号大小， $\text{rand}(\ast)$ 函数为a随机函数，在MATLAB中生成随机数。

同时，建立时域特征集，16个常用的时域统计特征参数见表2。原始肌电图被转换为统计特征数据集。在本研究中，传统的人工特征参数被定义为AF。

从表3可以看出，在不同的干扰系数下，与SVM、BP和ELM等传统人工特征参数的分类结果相比，AF-WDBN的分类效果最好，所有样本的平均准确率可以达到100%。但是，当干扰系数为0.4时，SVD-WDBN的识别精度仍能达到100%。这表明所提出的SVD-WDBN混合识别模型具有很强的分类能力和良好的抗噪声性能。一般来说，上述四种分类方法的识别精度随着干扰系数的增加而降低。当SEMG信号的干扰系数增加到0.8时，SVM、BP和ELM分类器的结果都低于65%，但SVD-WDBN的识别精度仍保持在95%左右。值得注意的是，当干扰系数设置为0.2和0.8时，SVD-WDBN分类精度的下降差距只有0.058。相比之下，其他三个分类器的识别精度在0.2和0.8之间有一个浮动的差距。0.3.这表明，WDBN的范围在整个还原范围内是最小的。深度学习可以实现对复杂函数的逼近，表示输入数据的表征分布，并表现出从少量样本中学习数据集的基本特征的巨大能力。在本研究中，SVD-WDBN的稳定性和泛化能力被证明是最好的，它适用于上肢SEMG信号的单通道自动识别。

在本文中，对运动识别模型的探索仅限于三个关节的基本运动的分类，而

表2
时域统计特征参数。

数量	特征参数	数量	特征参数
1	平均值	9	峰度
2	平均平方振幅	10	标准偏差
3	振幅的平方根	11	波形指数
4	平均振幅	12	峰值指数
5	最大值	13	推力指数
6	最低值	14	容忍指数
7	峰值到峰值	15	坡度指数
8	倾斜度	16	峰度指数

表3
不同分类方法的平均数。

干扰系数	$g \in \{0.2\}$	$g \in \{0.4\}$	$g \in \{0.6\}$	$g \in \{0.8\}$	平均值
AF-SVM	0.85	0.75	0.7	0.65	0.738
AF-ELM	0.9	0.813	0.708	0.6	0.755
AF-BP	0.833	0.75	0.667	0.563	0.703
AF-WDBN	1	0.967	0.917	0.85	0.934
SVD-WDBN	1	1	0.967	0.942	0.977

人类的上肢运动是连贯而复杂的，因此未来的工作将集中在识别上肢的空间连贯运动和增加样本数据库。同时，数据流分割和移动窗口的结合将增强系统中动作识别的一致性，避免不同外围设备的延迟效应。另一方面，深度学习的超参数调整一直是一个问题。如何保证训练后的模型参数具有良好的泛化能力，这对实际工程应用有很大的积极意义。因此，我们将在未来探索模型的参数优化和调整技术，防止模型过拟合。

3.5. 拟议模型和数据库的实验验证

在人类运动识别中，手势是一种复杂而精细的运动，因此手势识别对模型性能提出了更高的要求。因此，为了验证所提方法的有效性，我们选择了通过8个通道收集的四种手势的EMG数据，这些数据来自Kaggle中的Kirill（2018）。这四个手势包括石头、剪刀、纸和OK。每个手势以200HZ记录6次，持续20秒。每个手势在一个固定的位置停留120s。在这一部分，我们随机选择了四个通道（Ch1/Ch3/Ch5/Ch7）进行识别。滑动窗口用于处理信号，形成整个实验的数据样本。移动窗口的大小为50，时间长度为200。每个手势共获得40个数据样本。这里，我们参考前几节的数据处理方法。由于空间有限，我们在Ch1的基础上随机选择手势3数据，在图12中显示SVD降噪前后的时域波形和频谱。

经过SVD处理，图12中的时域波形和频谱都显示出良好的性能。特别是从频谱上看，我们可以看到信号特征得到了加强。能量冲击成分出现在40Hz和50Hz之间，这为提高模型识别率提供了基础。

一个手势是由许多小肌肉群完成的，不同的肌肉通道表现出不同的识别效果。这是因为有些肌肉属于合作运动，有些肌肉属于主动运动，并不是每个肌肉通道都在完成一个复杂的动作中起主要作用。从表4中所有四个通道的识别率可以看出，去噪信号的分类效果明显高于原始信号。然而，降噪后的最佳识别率只有87.5%，仍有一些动作还没有被准确识别。其原因可能是手势属于精细动作，手部肌肉之间的协同作用比较大，小肌肉群产生的振动能量容易重叠，所以很难从一个通道中识别多个手势。此外，开放数据的采样率只有200HZ，可能无法捕捉到原始信号的所有有效特征。

图13显示了Ch1上四种手势的测试样本的更详细分类。可以看出，去噪后，手势1（岩石）的识别率可以达到100%，但手势3（纸张）的识别率仍然最差。这可能是由于手的伸展运动所产生的肌肉振动能量低于手的伸展运动。

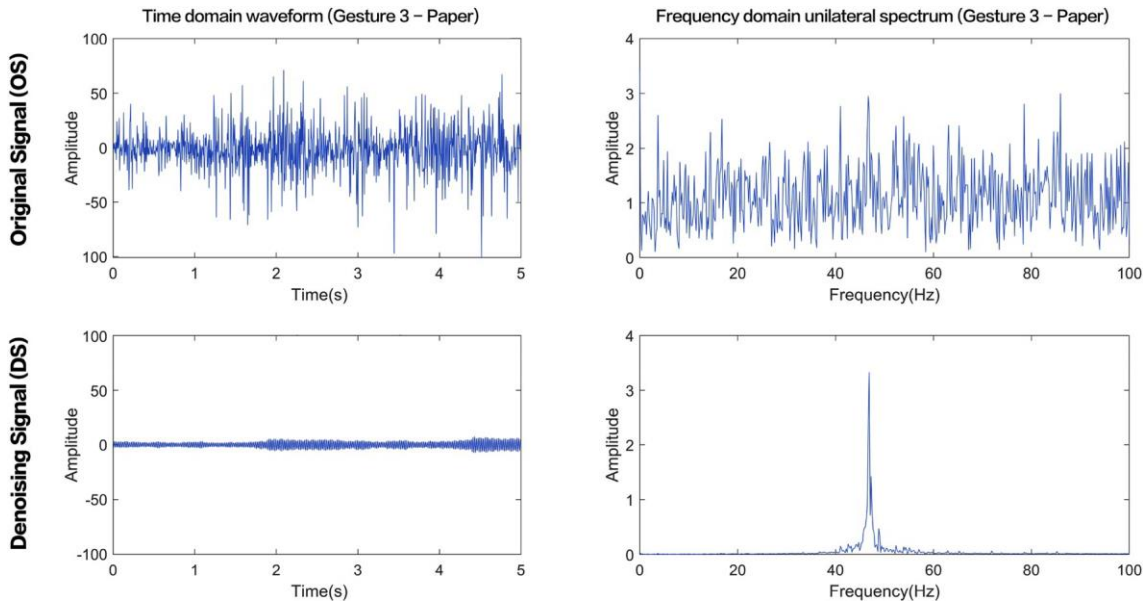


图12.Ch1的时域波形和频谱（手势3-纸）。

表4
四种手势的测试样本的识别率。

输入信号	Ch1	Ch3	Ch5	Ch7
OS	0.613	0.763	0.588	0.725
DS	0.775	0.875	0.75	0.838

收缩运动，这不利于识别。尽管如此，通过使用基于单通道的SVD-WDBN模型，对四种精细手势的识别率可以接近90%。这些结果基本验证了所提方法的有效性。我们相信，通过提高数据采样率，选择适当的肌肉通道，以及重新优化模型，单通道识别可以达到更令人满意的手势效果。

4.结论

在本文中，每个关节的SEMG信号是通过两个通道收集的。原始信号经过SVD降噪处理后，FFT处理后的频谱信号被输入到WDBN模型中。通过比较两个通道的识别，确定每个关节的最佳单通道。基于三个接头收集的最佳单通道数据，WDBN和其他接头的总识别率分别为

分类器进行了比较。结果表明，SVD-WDBN方法不再依赖人工特征提取，比传统方法和标准深度学习方法更有效。本文创造性地将奇异值分解、小波函数和深度信念网络相结合，进一步拓展了单通道SEMG信号识别方法的研究。

知情同意

所有纳入研究的个人参与者都获得了知情同意。

伦理批准

对伦理批准没有要求。

竞争性利益的声明

作者声明，他们没有利益冲突。

CRedit作者的贡献声明

邵俊凯。方法学，软件，形式分析，写作-原稿。Yafeng Niu: Methodology, Investigation, Writing -

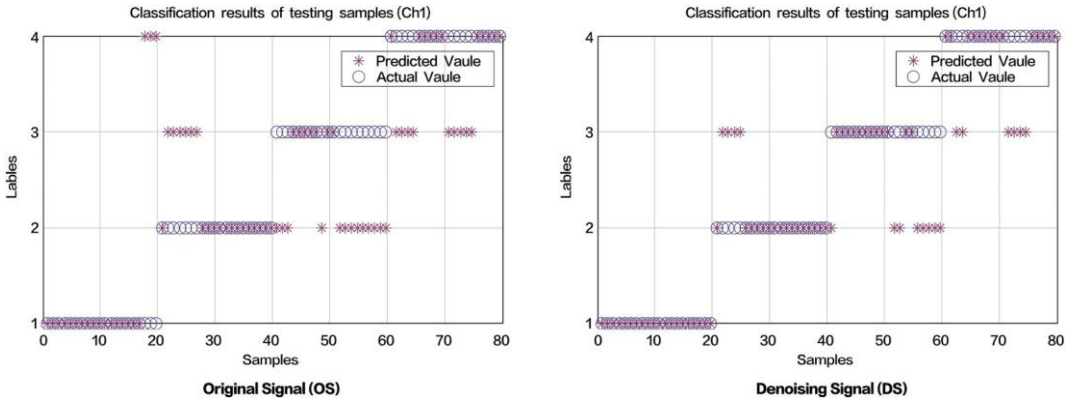


图13.对Ch1上的四个手势的测试样本的分类。

审查和编辑。**薛成奇**。概念化，监督，资金获取。**吴群**。概念化，方法学。**周小舟**：可视化，数据整理。视觉化，数据整理。**谢毅**：资金获取，项目管理。**赵晓丽**：软件，验证。

鸣谢

作者对审稿人的意见表示感谢。这项工作得到了国家自然科学基金（编号：71871056，71801037，71901061），江苏省研究生研究与实践创新计划（编号：SJKY19_0067），航空电子集成实验室和航空科学基金的科技支持（编号：20165169017，20185569008），中国科技部基金（SAST No.20165169017，20185569008），中国SAST基金（SAST No.2016010），装备预研与教育部联合基金，中国中央高校基础研究基金（No.2242019k1G023）。

附录A. 补充数据

本文的补充数据可在网上找到：<https://doi.org/10.1016/j.ergon.2019.102905>。

参考文献

- Cao, H., Sun, S., Zhang, K., 2015.使用极端学习机对基于EMG的手握力进行修正的预测. *Soft Comput* 21 (2), 1-10.
- Chambon, S., Galtier, M.N., Arnal, P.J., Wainrib, G., Gramfort, A., 2018.使用多变量和多模态时间序列进行时间性睡眠阶段分类的深度学习架构。 *I EEE Trans.Neural Syst.Rehabil.Eng.* 26 (4), 758-769.
- Chen, Y., Zhao, X., Jia, X., 2015.基于深度信念网络的高光谱数据光谱-空间分类. *IEEE J. Sel.Top.Appl. Earth Obs.遥感.* 8 (6), 2381-2392.
- Chen, J., Zhang, X., Cheng, Y., Xi, N., 2018.基于表面EMG的人类下肢关节角度的连续估计，使用深度信念网络。 *Bio med.信号处理。控制* 40, 335-342.
- Chowdhury, R. H., Reaz, M. B. I., Ali, M. A. B. M., Bakar, A. A. A., Chellappan, K., Chang, T. G., 2013.表面肌电图信号处理和分类技术。 *Sensors* 13 (9), 12431-12466.
- Constantinescu, G., Jeong, J.W., Li, X., Scott, D.K., Jang, K.I., Chung, H.J., 等, 2016.肌电图的表皮电子设备：在吞咽治疗中的应用。 *Med.Eng.* 38 (8), 807-812.
- Geethanjali, P., Ray, K.K., 2011.用于控制假手的多通道EMG信号的运动识别。 *Australas.Phys. Eng.Sci. Med.* 34 (3), 419-427.
- Hinton, G., Deng, L., Dong, Y., George, E.D., Abdel, R.M., Navdeep, J., 2012.用于语音识别声学建模的深度神经网络：四个研究小组的共同观点。 *IEEE Signal Process.Mag.* 29 (6), 82-97.
- Jiang, H., Chen, J., Dong, G., Liu, T., Chen, G., 2015.基于Hankel矩阵的SVD研究及其在滚动体轴承故障诊断中的应用. *Mech.Sys t.Signal Process.* 52-53 (1), 338-359.
- Karimi, M., 2012.基于奇异值分解和小波包转换特征的前臂EMG信号分类. *Adv. Mater.Res.* 433-440 (2), 912-916.
- Khan, M.M., Mendes, P., Zhang, p., Chalup, S.K., 2017.使用笛卡尔遗传编程进化多维小波神经网络进行分类。 *Neurocomputing* 247, 39-58.
- Khushaba, R.N., Kodagoda, S., Takruri, M., Dissanayake, G., 2012.使用表面肌电图(EMG)信号改善假体手指的控制。 *Expert Syst.应用。* 39 (12), 10731-10738.
- Kirill, Y., 2018.通过阅读肌肉活动对手势进行分类。 <https://www.kaggle.com/kyr7plus/emg-4>.
- Lehtola, L., Karsikas, M., Koskinen, M., Huikuri, H., Seppanen, T., 2008.噪声和滤波器对基于SVD的心电图T波形态学参数的影响。 *J. Med.Eng.Technol.* 32 (5), 400-407.
- Liu, H.Y., Wang, L.H., 2018.人类与机器人协作的手势识别：回顾。 *Int.J. Ind.Ergon.* 68, 355-367.
- Matrone, G., Cipriani, C., Carrozza, M., Magenes, G., 2012.利用主成分分析对多指手部假体进行实时肌电控制。 *J.NeuroEng.Rehabil.* 9 (1), 40-52.
- O'Connor, P., Neil, D., Liu, S.C., Delbruck, T., Pfeiffer, M., 2013.用秒表的深度信念网络进行实时分类和传感器融合。 *Front.Neurosci.* 7 (7), 1-13.
- Patidar, M., Jain, N., Agrawal, P., 2013.基于奇异值分解和神经网络的EMG信号分类。 *Int.J. Sci. Eng.Res.* 4 (6), 956-960.
- Phinyomark, A., Quaine, F., Charbonnier, S., Serviere, C., Bernard, F.T., Laurillau, Y., 2013.用于提高肌电模式识别稳健性的EMG特征评估。 *Expert Syst.Appl.* 40 (12), 4832-4840.
- Rekhi, N.S., Arora, A.S., Singh, H., 2011.局部判别分析和奇异值分解在表面肌电信号分类中的比较。 *Acad.Res. Int.* 1 (2), 84-88.
- Tamilselvan, P., Wang, P., 2013.使用基于深度信念学习的健康状态分类进行故障诊断。 *Reliab.Eng.Syst.Sa f.* 115 (7), 124-135.
- Wu, Q., Shao, J.K., Wu, X.H., Zhou, Y.J., Liu, F.P., Xiao, F., 2017.基于SEMG的LLE-ELM方法的上肢运动识别. *Int.J. Pattern Recognit.Artif.Intell.* 31 (6), 1-16.
- Xia, P., Hu, J., Peng, Y., 2018.基于EMG的肢体运动估计，使用深度学习的递归卷积神经网络。 *Artif.Org ans* 42 (5), 67-77.
- Xiong, A., Ding, Q., Zhao, X., Han, J., Liu, G., 2016.基于单通道sEMG分解的手势分类. *J. Mech.Eng.* 52 (7), 175-179.
- Yan, X., Liu, Y., Jia, M., et al., 2019a.不同工况下滚动体轴承的多阶段混合故障诊断方法. *IEEE Access* 7, 138426-138441.
- Yan, X., Liu, Y., Jia, M., 2019b.基于多域指标的优化叠加去噪自动编码器的滚动轴承健康状态识别. *Struct. 健康监测。* 1475921719893594.
- Yang, H.J., Hu, X., 2016.小波神经网络与改进的遗传算法用于交通流时间序列预测. *Optik- International Journal for Light and Electron Optics* 127 (19), 8103-8110.
- Yang, Z.L., Chen, Y.M., Wang, J.P., Gong, H., 2017.用人工神经网络从呼吸和sEMG信号识别佩戴呼吸器的呼吸阻力。 *Int.J. Ind.Ergon.* 58, 47-54.
- Zhao, X., Ye, B., 2009.基于Hankel矩阵的SVD和小波变换的信号处理效果的相似性及其机制分析. *Mech.Syst.Signal Process.* 23 (4), 1062-1075.